



超声图像脂肪肝二分类实验报告

1. 任务说明

本实验完成超声图像脂肪肝二分类任务。任务目标是根据 B-mode 肝脏超声图像判断样本属于正常肝脏或脂肪肝。

实验要求如下：

- 使用 `Fatty-Liver-public` 文件夹中的公开数据作为训练集和验证集，并按 8:2 随机划分。
- 使用 `Fatty-Liver-private-test` 文件夹中的数据作为独立测试集。
- 至少训练 3 个分类网络模型。
- 报告各模型网络结构、超参数设置和训练参数。
- 绘制 training loss curve 和 validation loss curve。
- 在独立测试集上比较 Accuracy、Precision、Recall、F1-score 的均值和标准差。
- 将各模型与最优模型进行双边 t 检验，报告 t 值和 p 值。
- 对相同测试图像给出 Grad-CAM 可视化分类解释。
- 说明 AI 大模型辅助使用情况。

2. 数据集与划分

公开训练数据来自 Kaggle 数据集 `dataset-of-bmode-fatty-liver-ultrasound-images`。本实验仅将公开数据用于训练集和验证集；老师提供的 `Fatty-Liver-private-test` 仅用于最终独立测试，未上传至公开平台。

类别定义：

标签	含义
0	正常肝脏
1	脂肪肝

数据划分采用分层随机划分，保证训练集和验证集类别比例基本一致。随机种子为 42。

数据集	正常	脂肪肝	总数
训练集	136	304	440
验证集	34	76	110
独立测试集	37	66	103

训练集存在类别不平衡，脂肪肝样本多于正常样本。因此本实验使用加权交叉熵作为损失函数，属于对类别不平衡问题的处理。

3. 数据预处理与增强

所有图像统一处理为 3 通道 RGB 输入，以兼容 ImageNet 预训练模型。灰度超声图像通过复制通道转换为 RGB。

输入尺寸统一为 224×224 。

训练集增强策略：

操作	参数
Resize	224×224
RandomHorizontalFlip	$p = 0.5$
RandomRotation	$\pm 10^\circ$
ColorJitter	brightness = 0.12, contrast = 0.12
Normalize	ImageNet mean/std

验证集和测试集仅执行 Resize、ToTensor 和 Normalize，不使用随机增强。

归一化参数：

通道	mean	std
R	0.485	0.229
G	0.456	0.224

通道	mean	std
B	0.406	0.225

4. 模型设置

本实验训练 3 个分类网络：

- 1. ResNet18
- 2. MobileNetV3-Small
- 3. EfficientNet-B0


所有模型均使用 ImageNet 预训练权重，并将最后分类层替换为 2 分类输出层。

4.1 ResNet18

ResNet18 使用残差连接缓解深层网络训练中的梯度退化问题。其主体由 BasicBlock 组成，每个 BasicBlock 包含卷积、BN、ReLU 和 shortcut 分支。

网络拓扑图：

ResNet18



结构概述：

阶段	输出通道	说明
Conv stem	64	7×7 卷积, stride = 2
MaxPool	64	3×3 最大池化
Layer1	64	BasicBlock $\times$ 2


阶段	输出通道	说明
Layer2	128	BasicBlock × 2, 下采样
Layer3	256	BasicBlock × 2, 下采样
Layer4	512	BasicBlock × 2, 下采样
Global Average Pooling	512	全局平均池化
FC	2	二分类输出

4.2 MobileNetV3-Small

MobileNetV3-Small 是轻量级 CNN，核心结构包括 inverted residual block、depthwise separable convolution、Squeeze-and-Excitation 和 Hardswish 激活。该模型参数量小，适合医学图像小数据集上的快速训练和部署。

网络拓扑图：

MobileNetV3-Small



结构概述：

阶段	说明
Conv stem	初始卷积提取低级特征
Inverted residual blocks	使用 depthwise separable convolution 降低计算量
SE module	对通道特征进行自适应重标定


阶段	说明
Conv head	高层语义特征整合
Global Average Pooling	空间维度压缩
Classifier	输出 2 类预测

4.3 EfficientNet-B0

EfficientNet-B0 使用 compound scaling 思路，在网络深度、宽度和分辨率之间进行平衡。其基本模块为 MBConv，并引入 Squeeze-and-Excitation 结构。

网络拓扑图：

EfficientNet-B0



结构概述：

阶段	说明
Conv stem	初始卷积，提取基础纹理特征
MBConv1	低层特征提取
MBConv6 stages	多阶段通道扩展与下采样

阶段	说明
SE module	通道注意力
Conv head	高层特征整合
Global Average Pooling	空间聚合
Classifier	输出 2 类预测

5. 损失函数与超参数

5.1 损失函数

本实验使用加权交叉熵损失函数，以处理训练集中正常样本和脂肪肝样本数量不平衡的问题。

加权交叉熵定义为：

$$L = - \sum_{c=1}^C w_c y_c \log(p_c)$$

其中， $C = 2$ ， w_c 为类别权重， y_c 为真实标签的 one-hot 编码， p_c 为模型预测概率。

类别权重根据训练集样本数自动计算：

$$w_c = \frac{N}{C \cdot N_c}$$

训练集中：

- 正常类样本数 $N_0 = 136$
- 脂肪肝样本数 $N_1 = 304$
- 总样本数 $N = 440$

因此：

类别	样本数	权重
正常	136	1.6176

类别	样本数	权重
脂肪肝	304	0.7237

5.2 训练超参数

参数	设置
输入尺寸	224×224
Batch size	32
Epochs	30
随机种子	42, 43, 44
优化器	AdamW
初始学习率	0.0001
Weight decay	0.0001
学习率衰减	CosineAnnealingLR
Scheduler 参数	<code>T_max = 30</code>
损失函数	Weighted Cross Entropy
预训练权重	ImageNet
DataLoader workers	4

6. 实验环境

项目	配置
服务器	AutoDL
GPU	NVIDIA GeForce RTX 4090
显存	24 GB

项目	配置
Python	3.12
PyTorch	2.8.0+cu128
torchvision	0.23.0+cu128
CUDA	可用
主要依赖	numpy, pandas, scikit-learn, scipy, tensorboard, matplotlib, opencv-python-headless

7. 评价指标

独立测试集评价指标包括 Accuracy、Precision、Recall 和 F1-score。

设 TP、TN、FP、FN 分别表示真正例、真反例、假正例和假反例。

Accuracy:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Precision:

$$Precision = \frac{TP}{TP + FP}$$

Recall:

$$Recall = \frac{TP}{TP + FN}$$

F1-score:


$$F1 = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall}$$

每个模型使用 3 个随机种子重复训练，最终报告测试集指标的均值和标准差。


8. 训练过程 Loss 曲线

所有模型训练过程中均记录 training loss 和 validation loss。每个模型的曲线为 3 个随机种子结果的均值，阴影区域表示标准差。

总体 loss 曲线：




ResNet18:




MobileNetV3-Small:

MobileNetV3-Small loss curves



EfficientNet-B0:

EfficientNet-B0 loss curves



从训练过程看，三个模型在训练集和验证集上均能收敛。其中 ResNet18 和 EfficientNet-B0 在验证集上很快达到接近 1.0 的分类表现，但在独立测试集上性能明显下降，说明公开数据和私有测试集之间存在域偏移。

9. 独立测试集结果

9.1 每个模型的均值和标准差

独立测试集结果如下。均值和标准差基于 3 个随机种子计算。

模型	Accuracy	Precision	Recall	F1-score
MobileNetV3-Small	0.5534 ± 0.0846	0.7721 ± 0.0311	0.4343 ± 0.2012	0.5377 ± 0.1490
ResNet18	0.4854 ± 0.0700	0.8155 ± 0.0247	0.2525 ± 0.1306	0.3743 ± 0.1523
EfficientNet-B0	0.4628 ± 0.0297	0.8009 ± 0.0289	0.2172 ± 0.0683	0.3373 ± 0.0830

按平均 F1-score 排序，MobileNetV3-Small 为最优模型。

9.2 单次实验结果

Run	Accuracy	Precision	Recall	F1-score
efficientnet_b0_seed42	0.4951	0.7917	0.2879	0.4222
efficientnet_b0_seed43	0.4369	0.8333	0.1515	0.2564
efficientnet_b0_seed44	0.4563	0.7778	0.2121	0.3333
mobilenet_v3_small_seed42	0.6505	0.7586	0.6667	0.7097
mobilenet_v3_small_seed43	0.5146	0.8077	0.3182	0.4565
mobilenet_v3_small_seed44	0.4951	0.7500	0.3182	0.4468
resnet18_seed42	0.5631	0.8387	0.3939	0.5361

Run	Accuracy	Precision	Recall	F1-score
resnet18_seed43	0.4272	0.8182	0.1364	0.2338
resnet18_seed44	0.4660	0.7895	0.2273	0.3529

9.3 结果分析

MobileNetV3-Small 的平均 F1-score 最高，主要原因是其 Recall 明显高于 ResNet18 和 EfficientNet-B0。ResNet18 和 EfficientNet-B0 的 Precision 较高，但 Recall 较低，说明它们更倾向于预测正常类，导致较多脂肪肝样本被漏判。

测试集性能低于验证集，主要原因可能包括：

- 私有测试集与公开训练数据来源不同，存在域偏移。
- 私有测试图像尺寸、成像质量、灰度分布和采集条件与公开数据不同。
- 数据集规模较小，模型容易在公开训练/验证集上过拟合。
- 正负样本不均衡使模型对少数类和域外样本更敏感。

因此，本实验的重点不是追求验证集高分，而是使用独立测试集评估模型泛化能力。

10. 双边 t 检验

以平均 F1-score 最高的 MobileNetV3-Small 作为最优模型。对 3 个随机种子下的测试集指标进行配对双边 t 检验。

10.1 F1-score t 检验

最优模型	对比模型	t 值	p 值
MobileNetV3-Small	ResNet18	4.3512	0.0490
MobileNetV3-Small	EfficientNet-B0	3.9891	0.0575

10.2 全指标 t 检验

对比模型	Accuracy t / p	Precision t / p	Recall t / p	F1 t / p
ResNet18	3.5000 / 0.0728	-2.1477 / 0.1648	3.4641 / 0.0742	4.3512 / 0.0490
EfficientNet-B0	2.6458 / 0.1181	-13.0982 / 0.0058	2.6266 / 0.1195	3.9891 / 0.0575

根据 F1-score 的 t 检验结果：




- MobileNetV3-Small 相比 ResNet18 的 F1-score 提升达到统计显著水平， $p = 0.0490 < 0.05$ 。
- MobileNetV3-Small 相比 EfficientNet-B0 的 F1-score 提升接近显著， $p = 0.0575$ 。

需要说明的是，每个模型仅重复 3 个随机种子，样本量较小，因此 t 检验结果应作为辅助统计证据，而不是唯一判断依据。




11. Grad-CAM 可视化解释

本实验对 3 个模型在同一批测试图像上生成 Grad-CAM 可视化结果。每张可视化图左侧为原始图像，右侧为 Grad-CAM 热力图叠加结果。热力区域表示模型对脂肪肝分类更关注的图像区域。




11.1 测试图像 0

模型	Grad-CAM	
MobileNetV3-Small		
ResNet18		
EfficientNet-B0		

11.2 测试图像 1

模型	Grad-CAM	
MobileNetV3-Small		
ResNet18		
EfficientNet-B0		

11.3 测试图像 2

模型	Grad-CAM
MobileNetV3-Small	
ResNet18	
EfficientNet-B0	

从可视化结果看，模型主要关注肝实质区域及局部高响应纹理区域。部分错误预测样本中，热力图可能集中在图像边缘、暗区或非典型纹理区域，提示模型仍可能受到数据域差异和背景伪特征影响。

12. 附加题：类别不平衡处理

本实验采用加权交叉熵处理训练集类别不平衡问题。正常类样本较少，因此其损失权重更高；脂肪肝类样本较多，因此其损失权重较低。

该方法的优点是实现简单，能直接嵌入交叉熵损失函数，不需要额外生成合成样本。相比 SMOTE，医学图像任务中直接在图像空间或特征空间合成样本可能引入伪影，因此本实验选择加权损失作为更稳妥的类别不平衡处理方法。

13. 结论

本实验完成了超声图像脂肪肝二分类任务，并比较了 ResNet18、MobileNetV3-Small 和 EfficientNet-B0 三种分类网络。

主要结论：

- MobileNetV3-Small 在独立测试集上取得最高平均 F1-score，为 0.5377 ± 0.1490 。
- ResNet18 和 EfficientNet-B0 的 Precision 较高，但 Recall 明显偏低，说明漏判脂肪肝样本较多。
- MobileNetV3-Small 相比 ResNet18 的 F1-score 提升具有统计显著性， $t = 4.3512$ ， $p = 0.0490$ 。
- MobileNetV3-Small 相比 EfficientNet-B0 的 F1-score 提升接近显著， $t = 3.9891$ ， $p = 0.0575$ 。
- 训练/验证集表现明显优于独立测试集，说明公开数据与私有测试集之间存在域偏移。
- Grad-CAM 可视化显示模型能关注部分肝实质区域，但在错误样本中仍可能受到背景或局部伪特征影响。

综合测试集性能和模型复杂度，MobileNetV3-Small 是本实验中最优模型。

14. GitHub 项目地址与公开说明

本实验的代码和非敏感结果文件已上传至 GitHub：

<https://github.com/pangchip14/fatty-liver-ultrasound-classification>

该仓库用于保存本实验的可复现代码、模型训练脚本、测试评估脚本、统计检验脚本、网络拓扑

图、loss 曲线、汇总指标和报告文件。仓库中包含的主要内容如下：

内容	说明
<code>train.py</code>	训练 ResNet18、MobileNetV3-Small 和 EfficientNet-B0
<code>evaluate.py</code>	在独立测试集上计算 Accuracy、Precision、Recall 和 F1-score
<code>gradcam.py</code>	生成 Grad-CAM 分类解释图
<code>summarize_results.py</code>	汇总不同模型和随机种子的测试结果，并进行 t 检验
<code>export_report_assets.py</code>	导出报告所需的 loss 曲线、网络拓扑图和实验说明
<code>summary/</code>	保存非敏感的汇总指标、loss 曲线和网络拓扑图
脂肪肝二分类实验报告.md	Markdown 版实验报告
脂肪肝二分类实验报告.pdf	PDF 版实验报告

由于 `Fatty-Liver-private-test` 是老师提供的私有测试集，不具备公开授权，因此 GitHub 仓库中未上传以下内容：

- 原始数据集压缩包。
- 解压后的训练、验证和测试图像。
- 私有测试集图像。
- 模型 checkpoint 权重文件。
- 包含私有测试图像内容的 Grad-CAM 可视化图片。
- 打包结果压缩文件。

因此，该 GitHub 仓库主要用于代码复现和实验结果核查，不用于公开分发数据集。

15. AI 大模型使用说明

本实验使用 OpenAI Codex / GPT-5 作为 AI 编程与实验辅助工具。AI 主要参与以下工作：

- 分析作业要求并比较不同选题的可行性。
- 检查本地数据集结构，确认公开数据和私有测试集路径。
- 搭建 PyTorch 训练、验证、测试、t 检验和 Grad-CAM 可视化代码。

- 在 AutoDL RTX 4090 服务器上配置环境并运行实验。
- 整理实验输出，包括 loss 曲线、模型拓扑图、测试指标表和统计检验结果。
- 辅助撰写本 Markdown 实验报告。

AI 工具仅用于代码实现、实验组织和文本整理。实验方案选择、结果核查和最终报告内容由本人负责确认。

16. 附录：结果文件

主要结果文件如下：

文件	内容
summary/test_metrics_by_model.csv	3 个模型测试集均值和标准差
summary/test_metrics_by_run.csv	每个模型每个 seed 的测试结果
summary/paired_t_tests_by_seed.csv	基于 3 个 seed 的双边 t 检验
summary/loss_curves/	training loss 和 validation loss 曲线
summary/topologies/	3 个模型网络拓扑图
summary/gradcam/	本地保存的同一批测试图像 Grad-CAM 可视化，因包含私有测试图像内容，未上传 GitHub
summary/fatty_liver_results_summary.tar.gz	本地汇总打包文件，未上传 GitHub